

# **Arquitecturas Big Data**

Mario Pérez Esteso



@\_Mario\_Perez mario@geekytheory.com



# Índice


- 1. Introducción
- 2. Tecnologías de procesado
- 3. Arquitectura
- 4. Casos de estudio
- 5. Conclusiones





# In one day, enough information is consumed by internet traffic to fill

#### 168 MILLION DVDS.



# 294 BILLION emails are sent.






#### 2 MILLION BLOG POSTS

are written.

Enough posts to fill

Time Magazine for 770 years.





# **864,000 HOURS OF VIDEO**

are uploaded to YouTube.



That's 98 years of non-stop cat videos.



#### Internet users spend

#### **14.6 MINUTES**


viewing porn online.

The average fap session is 12 minutes.














#### **Apache Hadoop**

Hadoop está formado por los siguientes módulos:

- Hadoop Common.
- Hadoop Distributed Filesystem (HDFS).
- Hadoop YARN (Yet Another Resource Negociator).
- MapReduce.




# **Apache Hadoop MapReduce**





#### **Apache Hadoop MapReduce**



#### **Apache Spark**

Es considerado el primer software de código abierto que hace la programación distribuida realmente accesible a los científicos de datos.


Spark mantiene la escalabilidad lineal y la tolerancia a fallos de MapReduce, pero amplía sus bondades gracias a varias funcionalidades: **DAG** y **RDD**.

Spark SQL Spark Streaming MLlib (machine learning) GraphX (graph)

Apache Spark



## **Apache Spark - DAG (Directed Acyclic Graph)**





#### **Apache Spark - RDD (Resilient Distributed Dataset)**

Un objeto RDD permite a los programadores realizar operaciones sobre grandes cantidades de datos en clusters de una manera rápida y tolerante a fallos.

Mantener los datos en memoria puede mejorar el rendimiento de una aplicación considerablemente.



#### Sistemas de streaming



# % kafka








## **Apache Kafka**

Sistema de mensajería distribuido basado en publicación-suscripción.



#### **Apache Kafka**





#### **Apache Storm**


Se basa en una arquitectura maestro-esclavo y su objetivo es procesar datos en tiempo real.

Se compone de dos partes principales:

- Spout
- Bold




#### **Apache Storm**






## **Spark Streaming**







## **Spark Streaming**












#### **Arquitectura**





#### Detección de anomalías en redes


#### Caso de estudio - Detección de anomalías

#### **Conjunto de datos:**

4.9 millones de registros.

#### **Algoritmo:**

KMeans Clustering.



#### Predicción de fallos online


#### Caso de estudio - Predicción de fallos online

#### **Conjunto de datos:**

10661 líneas 88 columnas

#### **Algoritmo:**

Random Forests.



```
model = RandomForest.trainClassifier(
trainingData,
numClasses=10,
categoricalFeaturesInfo={},
numTrees=5,
featureSubsetStrategy="auto",
impurity='gini',
maxDepth=5,
maxBins=32)
```

#### Análisis de sentimientos en Twitter

#### Caso de estudio - Análisis de sentimientos

#### **Conjunto de datos:**

Mensajes en Twitter. <sup>1</sup><sub>2</sub> **Algoritmo:** <sup>3</sup><sub>4</sub>

```
1  oauth.consumerKey = XXXXXXXXXXXXXXXX
2  oauth.consumerSecret = XXXXXXXXXXXXX
3  oauth.accessToken = XXXXXXXXXXXXXX
4  oauth.accessTokenSecret = XXXXXXXXXXXXX
```

Recuento de palabras positivas y negativas.

#### Análisis de sentimientos en Twitter

#### Puntuación de mensajes

Time: 1436353630000 ms

3

4

```
(6187380632,RT @IvanaKottasova: Tried to buy a train ticket in Athens. Ït's free", I am told. "The banks are closed."#Greece) (6187380678,Greece has the opportunity to repudiate a lot of inconvenient foreign debt.)
```

```
twitterStream.
    map{tweet => (tweet.getId(), tweet.getText())}.
    map{case (id, text) => (id, clean(text))}.
    map{case (id, words) => (id, rateWordList(words))}.
    print()
```

Time: 1436361275000 ms

(618770130890133505,1)

(618770131334918144,0)

(618770132014362624,0)

(618770132144377856,0)

(618770133599825920,1)

(618770135097192448,0)

(618770136187727873, -1)

(618770136149790720,0)

(618770137676517376,1)

(618770138267914240, -2)



#### **Conclusiones**

Apache Spark es entre 10 y 100 veces más rápido que Hadoop MapReduce.

La programación es muy similar en Scala, Java y Python.

La arquitectura propuesta es válida para cualquier caso de estudio.



@\_Mario\_Perez mario@geekytheory.com